

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Московский Авиационный Институт»
(Национальный Исследовательский Университет)

Институт: №8 «Информационные технологии
и прикладная математика»
Кафедра: 806 «Вычислительная математика
и программирование»

Отчет по лабораторной работе №1
по предмету «Информационный поиск»

«Добыча корпуса документов»

Группа: М8О-412Б-22

Студент: Муратов А.А.

Оценка:

Дата сдачи:

Москва, 2025

Задание

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

Описание задания

Тема:

Статьи из российских СМИ. Выбранные мной источники - популярные СМИ, имеющие хорошо поддерживаемую структуру HTML и структуру сайтов.

Источники данных: www.interfax.ru, tass.ru.

Что внутри документов:

- Interfax: стандартный HTML с `og:*` мета-тегами, `article:published_time`, `article:tag`, `canonical/amp` ссылки, `favicon` и `CSS/JS`. Основной текст в блоке статьи, есть дата/время, рубрика, теги.
- TASS: HTML, собранный Next.js, содержит `og:*` и JSON-LD (`application/ld+json`), прелоады шрифтов/изображений, `data-v` атрибуты. Основной текст и заголовок в блоках с классами `article-page`, присутствуют дата, автор/редакция, рубрика. Исходный HTML был

минимизирован в одну строку. Большой размер документов по сравнению со вторым источником.

Доступные поисковики:

- Встроенный поиск Interfax: <https://www.interfax.ru/search/?sw=запрос> (ищет по всему сайту, без сложных фильтров).
- Встроенный поиск TASS: <https://tass.ru/search?text=запрос> (есть сортировка по дате/релевантности).
- Внешний: Google/Yandex с ограничением `site:interfax.ru` или `site:tass.ru`.

Примеры запросов и ограничения:

- `site:interfax.ru аэропорт Нижний Новгород`; выдача смешивает новости и обзоры, часто есть дубли по AMP/print.
- `site:tass.ru экономика нефть`; попадают лонгриды и дайджесты, нет контроля по дате, встречаются мультимедийные страницы без текста.
- `interfax поиск "Москва"` во встроенном поиске: нет фильтрации по рубрике, много старых материалов.
- `tass поиск "военная операция"` во встроенном поиске: релевантность слабая, выдаёт фотоленты и видео, которые плохо подходят для текстового корпуса.

Статистика корпуса:

Источник	Кол-во	Сырые байты (сум/сред)	Текст, символы (сум/сред)
InterFax	5	303 721 / 60 744	27 146 / 5 429
TASS	5	2 832 338 / 566 468	42 454 / 8 491

Выводы

Корпус документов используемый в работе пригоден для выполнения дальнейших работ, существует потенциал для улучшения поиска по данным сайтам.